

컴퓨터교육학회 논문지 2025년 제28권 제7호
<https://doi.org/10.32431/kace.2025.28.7.009>



기상 변수 통합 순환 신경망을 활용한 제주시 전력 수요 예측*

Power Demand Forecasting in Jeju Using a Recurrent Neural Network with Integrated Weather Variables

정현수[†] · 길준민^{††}

Hyunsu Jeong[†] · Joon-Min Gil^{††}

요약

제주특별자치도의 탄소중립 정책에 따라, 지역 단위의 정밀한 전력 수요 예측의 중요성이 증가하고 있다. 본 연구에서는 제주시의 시간대별 전력 수요 예측 정확도를 향상시키기 위해, 기온과 지중온도 등 주요 기상 변수를 통합한 순환 신경망 기반 모델을 제안한다. 피어슨 상관계수를 활용하여 기상 변수와 전력 수요 간의 상관성을 분석하고 이를 기반으로 예측 모델의 입력 변수로 사용할 변수를 선정한다. 기온 및 지중온도를 포함한 모델과 포함하지 않은 모델 간의 예측 성능을 비교한 결과는 모든 모델이 기상 변수를 포함했을 때 평균 절대 오차(MAE), 평균 제곱 오차(MSE), 결정 계수(R²) 측면에서 성능이 향상됨을 보여준다. 이는 기상 조건이 전력 수요에 유의미한 영향을 미친다는 점을 시사하며 제주시의 전력 수요 예측 정밀도 향상에 기상 데이터 통합이 효과적임을 보여준다.

주제어 전력 수요 예측, 피어슨 상관계수, 기상 데이터, 순환 신경망, 장단기 메모리, 양방향 장단기 메모리

ABSTRACT

In line with Jeju Special Self-Governing Province carbon neutrality policy, the importance of accurate, region-specific power demand forecasting has been increasing. This study proposes a recurrent neural network-based model that integrates key weather variables such as air temperature and ground temperature to improve the accuracy of hourly power demand forecasting in Jeju City. Pearson correlation coefficients were used to analyze the relationship between weather variables and power demand, and the selected variables were incorporated into the input features of the prediction models. Comparative experiments between models with and without the inclusion of weather variables confirmed that all models showed improved performance in terms of MAE (Mean Absolute Error), MSE (Mean Squared Error), and the coefficient of determination (R²) when weather variables were included. These results suggest that weather conditions have a significant influence on power demand and demonstrate the effectiveness of incorporating weather data in enhancing the forecasting precision for Jeju City.

Keywords Power demand forecasting, Pearson correlation coefficient, Weather data, RNN, LSTM, BiLSTM

[†]정회원 제주대학교 일반대학원 컴퓨터공학과 석사과정

^{††}중신회원 제주대학교 컴퓨터공학과 교수(교신저자)

논문투고 2025년 07월 03일

심사완료 2025년 07월 25일

게재확정 2025년 07월 28일

발행일자 2025년 07월 31일

* 이 연구는 2019년도 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 제주대학교 기초과학연구소 자율운영중점연구지원사업에서 수행된 기초연구사업임(RS-2019-NR040080)

* 본 논문은 2024년 한국정보기술학회 추계종합학술대회에서 “제주시 전력 수요 예측을 위한 RNN계열 모델과 기상 변수 통합 분석”의 제목으로 발표된 논문을 확장한 것임.

1. 서론

기후 변화에 대한 대응과 지속 가능한 환경에 대한 요구가 증가함에 따라, 전 세계적으로 신재생에너지의 도입이 빠르게 확산되고 있다. 이에 발맞추어, 제주도는 '탄소 없는 섬 2030(Carbon Free Island 2030)[1]' 프로젝트를 통해 2030년까지 전력 수요의 100%를 신재생에너지로 충당하여 탄소 배출 없는 지역을 구현하는 것을 목표로 한다.

이를 위해 제주도는 태양광 1,411MW와 풍력 2,345MW를 포함한 총 4,085MW 규모의 신재생에너지 설비 구축을 계획하고 있으며, 고전압 직류 송전(HVDC) 의존도는 줄이고 대규모 에너지 저장 시스템(ESS)의 활용을 통해 전력 계통의 안정성과 유연성을 강화하고자 한다. 그러나 신재생에너지는 기상 조건에 따라 발전량이 크게 변동되는 특성을 가지고 있다. 따라서, 발전 설비가 분산된 제주도에서 수요와 공급을 균형 있게 맞추기 위해서는 지역별 전력 관리가 필수적이다. 특히 제주시와 서귀포시와 같은 주요 지역에서 생산되는 전력을 중앙 송전 방식 대신 각 지역에서 직접 소비하는 분산형 운영 방식이 효율적인 전력 운용에 기여할 수 있다.

하지만 지역별 전력 수요를 정확히 예측하지 못할 경우에는 출력 제한 조치가 발생하며 이는 전력 낭비 및 계통 효율 저하로 이어질 수 있다. 이러한 문제를 최소화하기 위해서는 지역의 특성을 반영한 고도화된 전력 수요 예측 모델이 필요하다. 기존의 제주도 전력 수요 예측 연구에서 기온이나 지중온도와 같은 기상 변수를 통합하여 예측에 활용한 사례는 드물었으며, 해당 기상 변수를 정량적으로 분석하고 예측 모델에 적용한 연구는 더욱 미미한 수준이다. 따라서 기상 변수와 전력 수요 간의 상관관계를 기반으로 한 지역 맞춤형 예측 모델 개발이 요구된다.

이러한 수요 예측을 위해 본 연구에서는 제주시의 특성에 맞는 기상 변수를 선별하여 순환 신경망(Recurrent Neural Network, RNN) 계열 모델을 학습하는 방법을 제안한다. 이를 통해 지역적 기상 요소가 전력 수요 예측 정확도 향상에 미치는 영향을 분석하고자 한다. 성능 평가를 위해 RNN, 장단기 메모리(Long Short-Term Memory, LSTM), 양방향 장단기 메모리(Bi-directional Long Short-Term Memory, BiLSTM) 모델을 사용하여 실험을 수행한다. 평균 절대 오차(MAE), 평균 제곱 오차(MSE), 결정 계수(R²) 기준으로 평가한다.

본 논문의 구성은 다음과 같다. 2장에서는 제주도의 전력 수요 예측 연구, 기상 데이터 기반 전력 수요 예측 연구, 시퀀스 길이를 고려한 전력 수요 예측 연구를 중심으로 관련 연구를 제시하고 3장에서는 본 연구에 사용된 전력 수요 데이터와 기상 데이터를 중심으로 데이터셋을 설명한다. 4장에서는 연구 방법론으로 기상 데이터 분석과 기상 변수 통합 전력 수요 예측 모델을 기반으로 한 예측 모델의 구성 및 학습 과정을 기술하고 5장에서는 모델의 예측 성능 평가 결과를 제시한다. 마지막으로 6장에서는 결론을 제시하고 향후

연구 방향에 대해 논의한다.

2. 관련 연구

2.1 제주도의 전력 수요 예측 연구

제주도는 재생에너지 보급률이 높고 기상 조건의 변화가 전력 수요에 큰 영향을 미치기 때문에, 이를 고려한 다양한 수요 예측 연구가 진행되어 왔다. P. W. Khan et al. (2020)은 제주도를 대상으로 에너지원 생산 데이터를 기반으로 한 전력 소비 예측을 위해 다층 퍼셉트론(Multi Layer Perceptron), 서포트 벡터 회귀(Support Vector Regression), CatBoost를 결합한 하이브리드 머신러닝 모델을 제안한다[2].

문형빈 외(2023)의 연구에서는 머신러닝 및 DNN(Deep Neural Network)을 활용하여 한국전력거래소의 제주도 전력 거래 데이터를 기반으로 제주도의 전력 수요를 예측한다[3]. 이 연구에서는 제주도 전체를 대상으로 하여 평일, 주말, 휴일 및 계절별로 데이터를 세분화해 학습을 수행하였으며, 기상 데이터를 전력 수요 예측의 독립 변수로 활용한다. 이를 통해 전력 수요의 주기적 변동성을 반영한다. 반면, 본 연구는 RNN 계열 모델을 사용하고 기상 데이터를 분석 및 상관관계가 높은 기상 데이터만 함께 학습에 포함시켜 제주시 전력 수요를 예측하고자 한다. RNN 계열 모델은 DNN에 비해 시계열 데이터의 순차적 패턴을 학습하는 데 유리한 장점을 가지고 있다. 전력 수요 데이터는 시간에 따른 연속적 변동성을 가지기 때문에, 이를 효과적으로 예측이 가능하며, 기상 데이터를 함께 사용하여 RNN 계열 모델이 시간에 따른 날씨의 변화와 전력 수요 간의 관계를 효과적으로 학습하도록 설계한다.

김동관 외(2024)의 연구에서는 3일 이동평균과 유사일 기반 전력 수요 예측 알고리즘을 통해 제주 계통의 요일 구분을 최적화하여 예측 성능을 향상시켰다[4]. 그러나 이러한 방법은 시계열 데이터 내의 장기적 패턴이나 비선형적인 관계를 반영하는데 제한적일 수 있다.

2.2 기상 데이터 기반 전력 수요 예측 연구

호주 퀸즐랜드 남동부 지역을 대상으로 한 전력 수요 예측 연구에서 Ghimire et al.(2023)는 전력 수요에 영향을 미치는 지역 기후 변수를 통합한 모델을 제안한다[5]. 이 연구에서는 온도, 강수량, 습도 등 다양한 기후 요소가 전력 소비 패턴에 미치는 영향을 분석한다. 이후 기후 요소가 전력 소비 패턴에 미치는 영향을 고려하여 전력 수요 데이터와 함께 기후 변수를 입력으로 사용하는 모델을 제시한다. 다양한 딥러닝 모델과의 비교 실험을 통해, 기후 변수의 통합이 전력 수요 예측 성능 향상에 기여함을 보여준다.

또한, Li et al.(2023)은 온도 변화가 전력 소비 행동에 중요한 영향을 미치며, 이를 모델에 반영할 경우 예측 성능이 향상된다고 주장한다. 이들은 온도 데이터와 일별 전

력 소비 데이터를 통합한 모델을 제안하며, 해당 모델은 98.39%의 예측 정확도를 보여준다[6]. 기존 연구들은 다양한 기후 요소를 모델에 포함했지만, 변수 선택 기준이 명확하지 않거나 단순 입력으로만 활용한 경우가 많다. 본 연구는 기상 변수와 전력 수요 간의 상관관계를 정량적으로 분석하고 유의미한 변수만 선별하여 예측 모델의 입력으로 사용한 점에서 차별성이 있다.

2.3 시퀀스 길이를 고려한 전력 수요 예측 연구

Miraki et al.(2024)는 전력 수요 예측에서 과거 시점의 중요성을 강조하며, 직전 1시간뿐 아니라 약 24시간 및 48시간 전의 시점 정보가 예측에 유의미하게 작용함을 실험을 통해 확인한다[7].

본 연구 역시 전력 수요가 하루 단위의 유사한 패턴을 갖는다는 점에 주목하여 과거 48시간 데이터를 활용하고 다음 1시간 수요를 예측하는 시계열 모델을 제시한다. 하지만 [7]에서의 연구가 건물 단위에 초점을 맞춘 데 비해, 본 연구는 제주도 전체를 대상으로 고해상도 데이터를 활용한다는 점에서 예측 단위와 범위에 있어 차이가 있다.

3. 데이터셋

3.1 전력 수요 데이터

본 연구에서 활용된 시간별 전력 사용량 데이터는 대한민국 제주특별자치도 제주도 지역을 대상으로 한 것이다. 해당 데이터는 한국전력공사(KEPCO)[8]에서 운영 중인 원격 검침 인프라(Advanced Metering Infrastructure, AMI) [8]를 통해 자동으로 수집된 전력 소비 정보이다. AMI 시스템은 실시간으로 전력 사용량을 측정하고 원격으로 데이터를 전송할 수 있는 지능형 계량 시스템으로 본 연구에서는 이 시스템을 통해 수집된 고해상도 시간 단위의 데이터를 분석에 활용한다. 연구에 사용된 데이터는 한국전력공사로부터 제공받은 것으로 수집 기간은 2021년 1월 1일부터 2023년 12월 31일까지 총 3년간의 데이터이다.

3.2 기상 데이터

본 연구에서 사용된 시간별 기상 데이터는 대한민국 기상청에서 운영하는 기상자료개방포털을 통해 제공되는 중관기상관측(Automated Synoptic Observing System, ASOS)[9] 데이터를 기반으로 한다. 해당 데이터는 제주특별자치도에 위치한 제주지방기상청에서 직접 관측한 데이터다. 연구에 활용된 기상 관측 데이터의 수집 기간은 2021년 1월 1일부터 2023년 12월 31일까지로 총 3년이며, 1시간 간격의 시계열 형태로 제공 받았다. 제공된 변수는 총 11종(기온, 지중온도, 풍속, 풍향, 습도, 증기압, 이슬점 온도, 현지 기압, 해면 기압, 전운량, 중하층운량)이다.

4. 연구방법론

4.1 기상 데이터 분석

본 연구에서는 2021년부터 2022년까지의 기상 데이터와 제주시의 전력 수요 데이터 사이의 상관관계를 분석하기 위해 피어슨 상관계수(Pearson correlation coefficient)를 활용한다. 피어슨 상관계수는 두 변수 간의 선형 관계의 강도와 방향을 나타내는 통계 지표로 값의 범위는 -1에서 1 사이를 갖는다. 상관계수가 1에 가까울수록 두 변수는 강한 양의 선형관계를 가지며, -1에 가까울수록 강한 음의 선형 관계를 가진다. 0에 가까우면 값은 두 변수 간에 선형적 상관관계가 거의 없음을 의미한다.

본 연구에서 변수 간의 선형적 영향력 판단을 위해 피어슨 계수를 사용한다. 상관계수의 절대값이 0.5 이상인 경우 상관성을 갖는 것으로 판단한다. 피어슨 상관계수 r 은 다음과 같이 정의된다.

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (1)$$

수식 (1)은 두 변수의 변화가 서로 얼마나 비슷하게 움직이는지를 표준화된 형태로 나타내는 지표이며, 두 변수 간의 선형 관계가 얼마나 강하고 어떤 방향인지를 정량적으로 평가할 수 있다.




Figure 1. August Power Demand Correlation Coefficient Analysis by Weather Variables

Fig. 1은 2021년 8월의 전력 수요와 기상변수의 상관계수를 나타낸다. 여름철의 온도와 지중온도가 전력 수요와 높은 상관관계를 보이는 것으로 나타났다. 이러한 결과는

여름철 기온 상승이 전력 수요 증가에 큰 영향을 미친다는 점을 나타낸다. 반면, 기온과 지중온도 이외의 변수들은 전력 수요와 낮은 상관계수를 보이며, 전력 수요에 미치는 영향이 상대적으로 적은 것으로 분석되었다. 이러한 분석 결과를 바탕으로 본 연구에서는 온도와 지중온도를 주요 입력 변수로 선정하여 전력 수요 예측 모델의 예측 정밀도를 높이고자 해당 기후 변수를 반영한다.

4.2 기상 변수 통합 전력 수요 예측 모델

Algorithm 1 Power Demand Forecasting with RNN-based Models

```

1: Input: Raw dataset  $D = \{(x_t, y_t)\}_{t=1}^T$ 
2: Output: Trained models for each configuration
3: Step 1: Missing Value Handling
4:   Apply linear interpolation to fill NaN values
5: Step 2: Unit Conversion
6:    $y_t \leftarrow y_t/1000$  ▷ kWh to MWh
7: Step 3: Normalization
8:    $x_t^* = \frac{x_t - \min(x)}{\max(x) - \min(x)}$ 
9: Step 4: Train/Test Split
10:  Split  $D^*$  into  $D_{\text{train}}$  and  $D_{\text{test}}$  by time
11: Step 5: Sequence Generation
12:  for  $t = 1$  to  $T - L_{\text{in}} - L_{\text{out}}$  step  $s$  do
13:     $X_t \leftarrow [x_t^*, \dots, x_{t+L_{\text{in}}-1}^*]$ 
14:     $Y_t \leftarrow [y_{t+L_{\text{in}}}, \dots, y_{t+L_{\text{in}}+L_{\text{out}}-1}]$ 
15:  end for
16: Step 6: Model Training
17:  for each dataset configuration  $\in \{\text{with temperature, without temperature}\}$  do
18:    Generate training/test sequences
19:    for model  $\in \{\text{RNN, LSTM, BiLSTM}\}$  do
20:      Train model on sequences
21:      Evaluate using MAE, MSE,  $R^2$ 
22:    end for
23:  end for

```

본 연구에서는 시계열 기반의 전력 수요 예측을 위한 순환 신경망 계열의 모델인 RNN, LSTM, BiLSTM을 활용한다. 전력 수요는 일반적으로 하루 24시간을 주기로 반복되는 단기적 패턴을 가지므로[7], 이러한 시간 의존성을 반영하기 위해 RNN을 기반 모델로 활용하였다. 그러나 실제 전력 수요는 날씨 변화, 요일, 계절성과 같은 장기적 패턴의 영향을 함께 받기 때문에 장기 의존성 학습에 유리한 LSTM을 추가로 도입한다. 아울러, BiLSTM은 입력 시퀀스 내의 시간 정보를 양방향으로 처리할 수 있는 구조를 가지며, 이를 통해 특정 시점의 예측에 있어 과거 및 인접 시점 간의 문맥 정보를 보다 효과적으로 반영할 수 있다. 이러한 구조적 특성의 차이가 전력 수요 예측 성능에 어떠한 영향을 미치는지를 분석하기 위해 세 모델을 선정한다.

모델 학습에는 2021년 1월 1일부터 2022년 12월 31일까지의 전력 수요 및 기상 데이터를 사용하였으며, 테스트는 2023년 1월 1일부터 12월 31일까지의 데이터를 기반으로 수행한다. 전체 학습 과정은 Algorithm- 1에 기술되어 있으며, 주요 절차는 다음과 같다.

결측값이 존재하는 경우 데이터의 연속성을 유지하기 위해 선형 보간법(linear interpolation)으로 보완하였고 전력 수요 단위는 kWh에서 MWh로 변환한다. 이후 입력 변수인 전력 수요, 기온, 지중온도에 대해 Min-Max 정규화를

수행한다. 이는 변수 간 수치적 범위 차이로 인한 학습 편향을 방지하고 모델의 학습 안정성과 수렴 속도를 향상시키기 위함이다.

시퀀스 생성 과정에서는 1시간 간격으로 수집된 데이터를 기준으로 과거 48개의 시점 데이터를 입력 시퀀스로 구성하고 이에 대응되는 다음 1시간 후의 전력 수요 값을 타겟 시퀀스로 설정한다. 입력 시퀀스는 슬라이딩 윈도우 방식으로 생성되며 1시간씩 이동하며 학습 데이터를 생성한다.

기상 변수의 포함 여부가 예측 성능에 미치는 영향을 평가하기 위해 두 가지 실험 조건을 구성한다. 첫 번째는 전력 수요만을 입력 변수로 사용하는 단일 변수 모델이며, 두 번째는 기온과 지중온도를 포함한 다변수 모델이다. 모델 구성은 다음과 같이 이루어진다. 각 실험 조건에 대해 RNN, LSTM, BiLSTM 모델을 각각 적용하였으며, 총 3개의 모델과 2개의 입력 조건의 조합으로 총 6가지의 모델 구성을 실험한다.

각 모델의 학습은 동일한 조건에서 수행되었으며, 사용된 주요 하이퍼파라미터 설정은 Table 1에서 보여준다. 옵티마이저(optimizer), 학습률(learning rate), 반복 횟수(epoch), 은닉 크기(hidden size), 배치 크기(batch size) 등은 모델 간 성능 비교의 공정성을 위해 동일하게 적용한다.

Table 1. Hyperparameter Settings for Each Model

| Model Hyperparameter | RNN | LSTM | BiLSTM |
|----------------------|-------|-------|--------|
| Optimizer | Adam | Adam | Adam |
| Learning Rate | 0.001 | 0.001 | 0.001 |
| Epoch | 100 | 100 | 100 |
| Hidden Size | 50 | 50 | 50 |
| Batch Size | 32 | 32 | 32 |

5. 성능 평가 및 결과 분석

본 연구에서 설계한 예측 모델들의 성능을 정량적으로 평가하고 기온 및 지중온도와 같은 기상 변수의 통합이 예측 정확도에 미치는 영향을 분석한다. 이를 위해 RNN, LSTM, BiLSTM 모델을 기반으로, 기상 변수 포함 여부에 따라 총 10회 반복 실험을 수행한다. 이는 모델 학습 초기 가중치 설정에 따른 결과 편차를 줄이고, 실험 결과의 신뢰도를 확보하기 위함이다. 성능 평가는 평균 절대 오차(MAE), 평균 제곱 오차(MSE), 결정 계수(R2)를 기준으로 수행하며, 본 연구에서 사용되는 MAE, MSE, R2는 다음과 같이 정의된다.

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{Y}_i - Y| \quad (2)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2 \quad (3)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (4)$$

여기서, n 은 데이터의 수를 나타낸다. Y_i 와 \hat{Y}_i 는 실제 값과 예측값을 각각 나타낸다. 그리고 \bar{Y} 는 실제값 Y_i 의 평균을 나타낸다.




Figure 2. MAE Comparison of Models With and Without Weather Variables




Figure 3. MSE Comparison of Models With and Without Weather Variables




Figure 4. R^2 Comparison of Models With and Without Weather Variables

기상 변수 포함 여부에 따른 총 10회 반복 실험 결과는 Fig. 2, Fig. 3, Fig. 4에 각각 박스 플롯 형태로 시각화하였다. Fig. 2는 MAE, Fig. 3은 MSE, Fig. 4는 R^2 를 기준으로

각 모델의 성능을 비교한 결과이다. 특히, BiLSTM 모델은 세 모델 중 평균 성능 및 최고 성능 지표가 가장 우수하게 나타났다으며, 이는 양방향 정보 활용을 통한 높은 표현력의 이점을 반영하는 결과로 해석된다. 그러나 동시에, 반복 실험 간 예측 성능의 분산이 크게 나타나 모델의 결과가 일관되지 않고 불안정한 경향을 보인다. 반면, LSTM 모델은 평균 성능에서는 BiLSTM에 비해 다소 낮은 값을 보였으나, 반복 실험 간 편차가 작고 성능 분포가 안정적으로 유지되어, 실제 적용 측면에서 보다 신뢰성 있는 예측 성능을 제공할 수 있을 것으로 나타났다.

Table 2. Power Demand Forecasting Performance

| measure \ Model | MAE | MSE | R^2 |
|-------------------|-------|--------|-------|
| RNN w/o Temp. | 5.993 | 79.311 | 0.984 |
| RNN with Temp. | 5.946 | 76.937 | 0.985 |
| LSTM w/o Temp. | 5.087 | 61.253 | 0.988 |
| LSTM with Temp. | 4.701 | 57.032 | 0.989 |
| BiLSTM w/o Temp. | 4.774 | 56.874 | 0.989 |
| BiLSTM with Temp. | 4.69 | 55.685 | 0.989 |

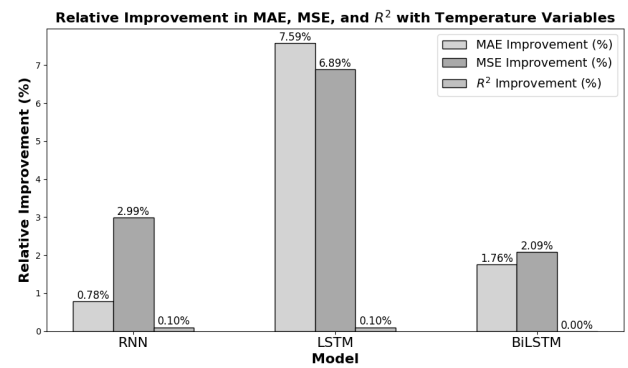


Figure 5. Performance Improvement Rate when Temperature Variables Are Used

Fig. 5는 온도 변수들을 포함한 모델과 제외한 모델 간의 성능 차이를 비교한 그래프이다. RNN, LSTM, BiLSTM 모델을 대상으로 MAE, MSE, R^2 기준에서 성능 향상을 상대 개선률(Relative Improvement, RI)로 표현하였으며, 다음과 같이 정의된다.

$$RI = \left| \frac{\text{with Temp} - \text{w/o Temp}}{\text{w/o Temp}} \right| \times 100 \quad (5)$$

Fig. 5와 같이 온도 변수를 포함한 모델이 포함하지 않은 모델에 비해 모든 지표에서 성능이 개선된 것을 확인할 수 있다.

6. 결론

본 연구는 제주특별자치도 제주시의 시간대별 전력 수요 예측 정확도를 향상시키기 위해, RNN 계열 모델에 기상 데이터를 통합하는 방안을 제안한다. 2021년부터 2022년까지의 전력 수요 및 기상 데이터를 기반으로 피어슨 상관관계 분석을 수행하여 전력 수요와 높은 상관관계를 갖는 기온과 지중온도를 주요 변수로 선정하고 해당 변수들을 포함한 모델과 포함하지 않은 모델 간의 예측 성능을 비교함으로써 기상 변수 통합의 효과를 실증적으로 분석한다.

실험 결과 온도 및 지중온도를 포함한 모델들이 모든 성능 지표에서 유의미한 상대적 성능 개선이 이루어졌다. 이는 기존 정보가 실제 수요 변화에 주요한 영향을 미친다는 점을 보여주며 제주도처럼 재생에너지 비중이 높은 지역에서 기상 변수 통합이 전력 수요 예측의 정밀도를 높이는 데 중요한 역할을 할 수 있음을 시사한다.

하지만 본 연구에는 몇 가지 한계점도 존재한다. 사용된 기상 변수는 상관관계를 기준으로 선택되었으나, 비선형 관계를 고려한 변수 선택 기법은 적용되지 않았다. 그리고 예측 대상은 제주시로 한정되어 있다.

향후 연구에서는 비선형 변수 선택 기법 및 서귀포시 등 다른 지역에 대한 비선형 변수 선택 기법과 지역 확장 가능성을 후속 연구를 통해 적용하고자 한다. 이러한 확장은 제주도 전역의 전력 수요 예측의 정확도를 높이는 데 기여할 수 있으며, 신재생에너지의 효율적인 운영을 위한 데이터 기반 의사결정 지원에 중요한 자료로 활용될 것이다.

참고문헌

- [1] OECD. (2023, January 24). *Carbon Free Island Jeju by 2030*. OECD OPSI. <https://oecd-opsi.org/innovations/carbon-free-island-jeju-by-2030/>
- [2] Khan, P. W., Byun, Y.-C., Lee, S.-J., Kang, D.-H., Kang, J.-Y., & Park, H.-S. (2020). Machine learning-based approach to predict energy consumption of renewable and nonrenewable power sources. *Energies*, 13(18), 4870. <https://doi.org/10.3390/en13184870>
- [3] Moon, H. B., Ahn, J., & Lee, C.-Y. (2023). Forecasting electricity demand of Jeju Island using machine learning. *Innovation Studies*, 18(4), 49–63. <https://doi.org/10.46251/INNOS.2023.11.18.4.49>
- [4] Kim, D., Jang, W.-J., Wi, Y.-M., & Joo, S.-K. (2024). Categorizing Electrical Day Types in Jeju Grid. *Proceedings of the 55th KIEE Summer Conference 2024, Jeju*, South Korea, 638–639.
- [5] Ghimire, S., Nguyen-Huy, T., AL-Musaylh, M. S., Deo, R. C., Casillas-Pérez, D., & Salcedo-Sanz, S. (2023). Integrated Multi-Head Self-Attention Transformer model for electricity demand prediction incorporating local climate variables. *Energy and AI*, 14, Article 100302. <https://doi.org/10.1016/j.egyai.2023.100302>
- [6] Li, X., Shang, W., Zhang, X., Shan, B., & Wang, X. (2023). Total electricity consumption forecasting based on temperature composite index and mixed-frequency models. *Data Intelligence*, 5(3), 750–766. https://doi.org/10.1162/dint_a_00215
- [7] Miraki, A., Parviainen, P., & Arghandeh, R. (2024). Electricity demand forecasting at distribution and household levels using explainable causal graph neural network. *Energy and AI*, 16, Article 100368. <https://doi.org/10.1016/j.egyai.2024.100368>
- [8] KEPCO. (n.d.). *KEPCO main page*. KEPCO. <https://www.kepc.co.kr/home/index.do>
- [9] KMA. (n.d.). *ASOS real-time weather data*. Korea Meteorological Administration. <https://data.kma.go.kr/data/grnd/selectAsosRltmList.do>

**정현수**

- 2024년 대구가톨릭대학교 모바일소프트웨어전공 (공학사)
- 2024년~현재 제주대학교 일반대학원 컴퓨터공학과 석사과정

✚ 관심분야: 클라우드, Kubernetes, MLOps

✉ jhs990909@stu.jejunu.ac.kr

**길준민**

- 1994년 고려대학교 전산학과(이학사)
- 1996년 고려대학교 전산학과(이학석사)
- 2000년 고려대학교 전산학과(이학박사)
- 2001년~2002년 일리노이대학(시카고) Post-Doc.
- 2002년~2006년 KISTI 슈퍼컴퓨팅센터 선임연구원
- 2006년~2010년 대구가톨릭대학교 컴퓨터교육과 교수
- 2010년~2023년 대구가톨릭대학교 컴퓨터소프트웨어학부 교수
- 2023년~현재 제주대학교 컴퓨터공학과 교수

✚ 관심분야: 클라우드컴퓨팅, 빅데이터, 인공지능, 분산컴퓨팅, 교육데이터분석

✉ jmgil@jejunu.ac.kr